Indexen

wim.bertels@ucll.be

INDEX

- Doel: beïnvloeden van de verwerkingstijd!

INDEX

- Doel: beïnvloeden van de verwerkingstijd!

OS:

- Rijen worden in bestanden opgeslagen
- Een bestand bestaat uit pagina’s
- Als een rij opgehaald wordt :
  - de betreffende pagina wordt opgehaald
  - de betreffende rij wordt opgehaald

Werking van een INDEX

- 2 methodes voor het opzoeken:
    - Sequentiële zoekmethode: rij voor rij
    - Tijdrovend en inefficiënt
- Geïndexeerde zoekmethode: index (B-tree)
    - Boom
    - Knooppunten
    - Leafpage (bevat referentie naar pagina+rij)
    - 2 methodes:
        - Zoeken van rijen met een bepaalde waarde
        - Doorlopen van de hele tabel via een gesorteerde kolom (geclusterde index)

B-tree (default)

- Binaire zoek boom (node kan 2+leaves hebben)
- Best voor > < = operatoren

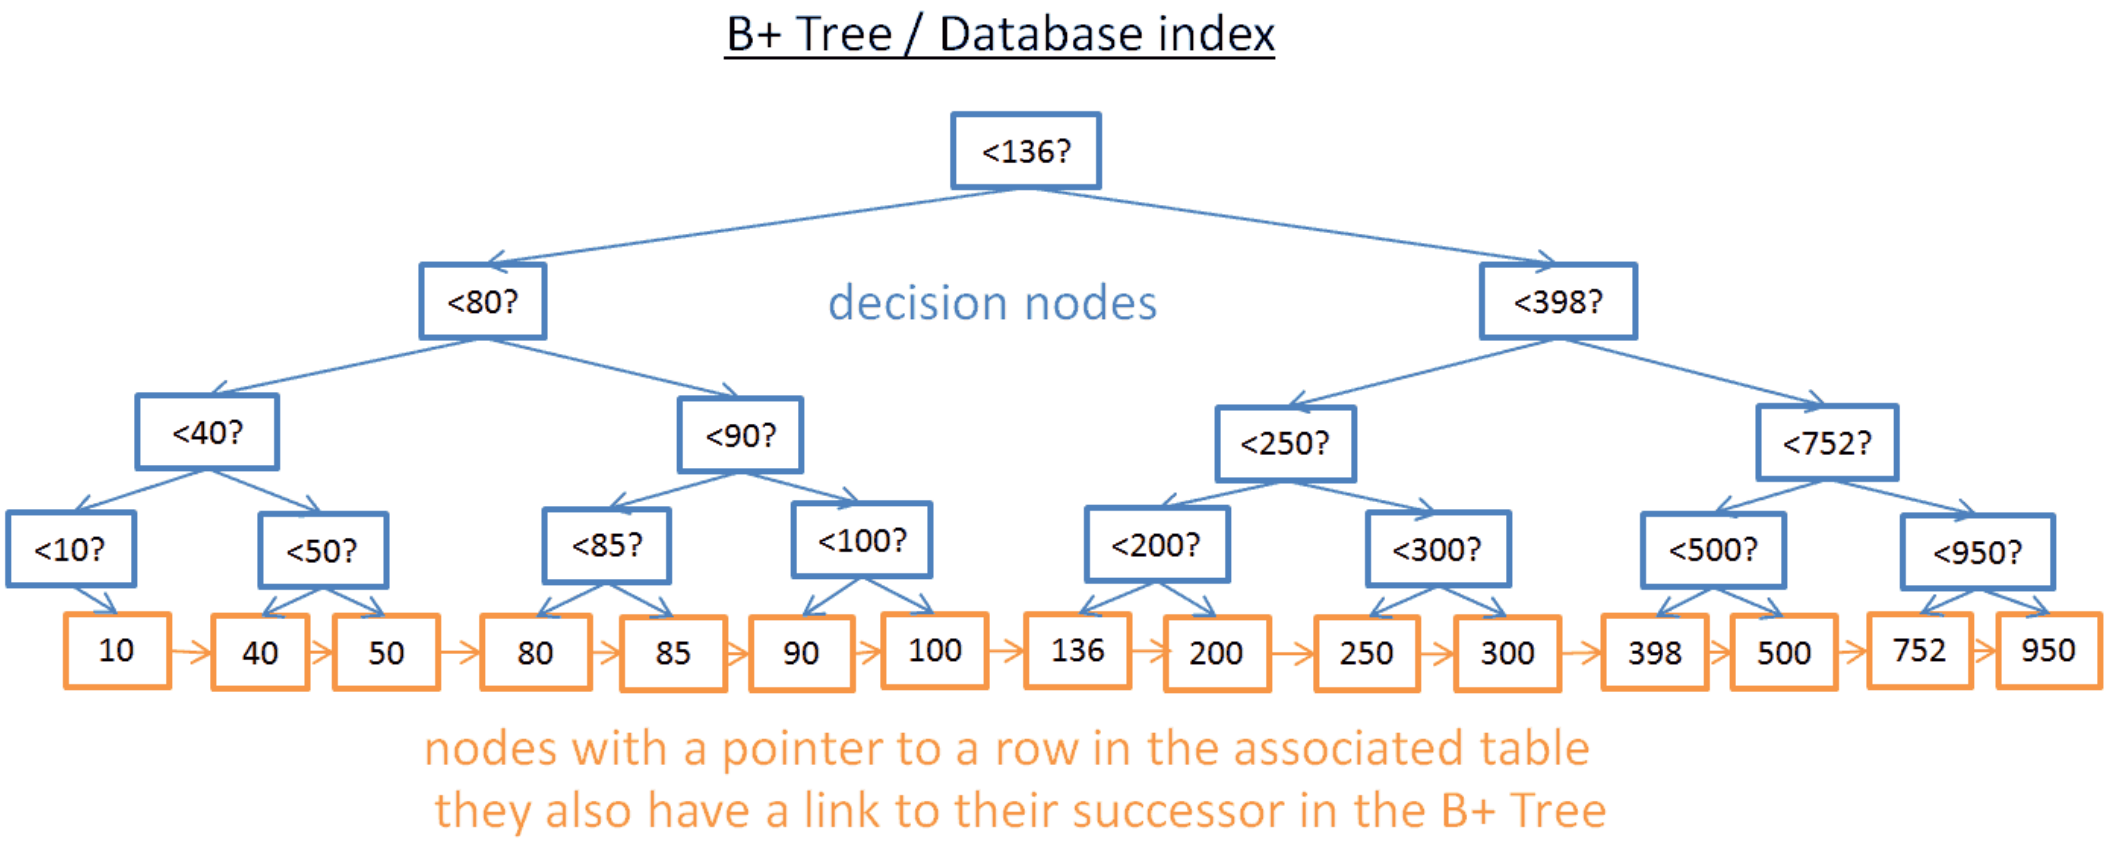

B-tree (voorbeeld)

- Sequentiel: max 15 stappen
- Via boom: max 4 stappen, namelijk +$\log_2 15$+

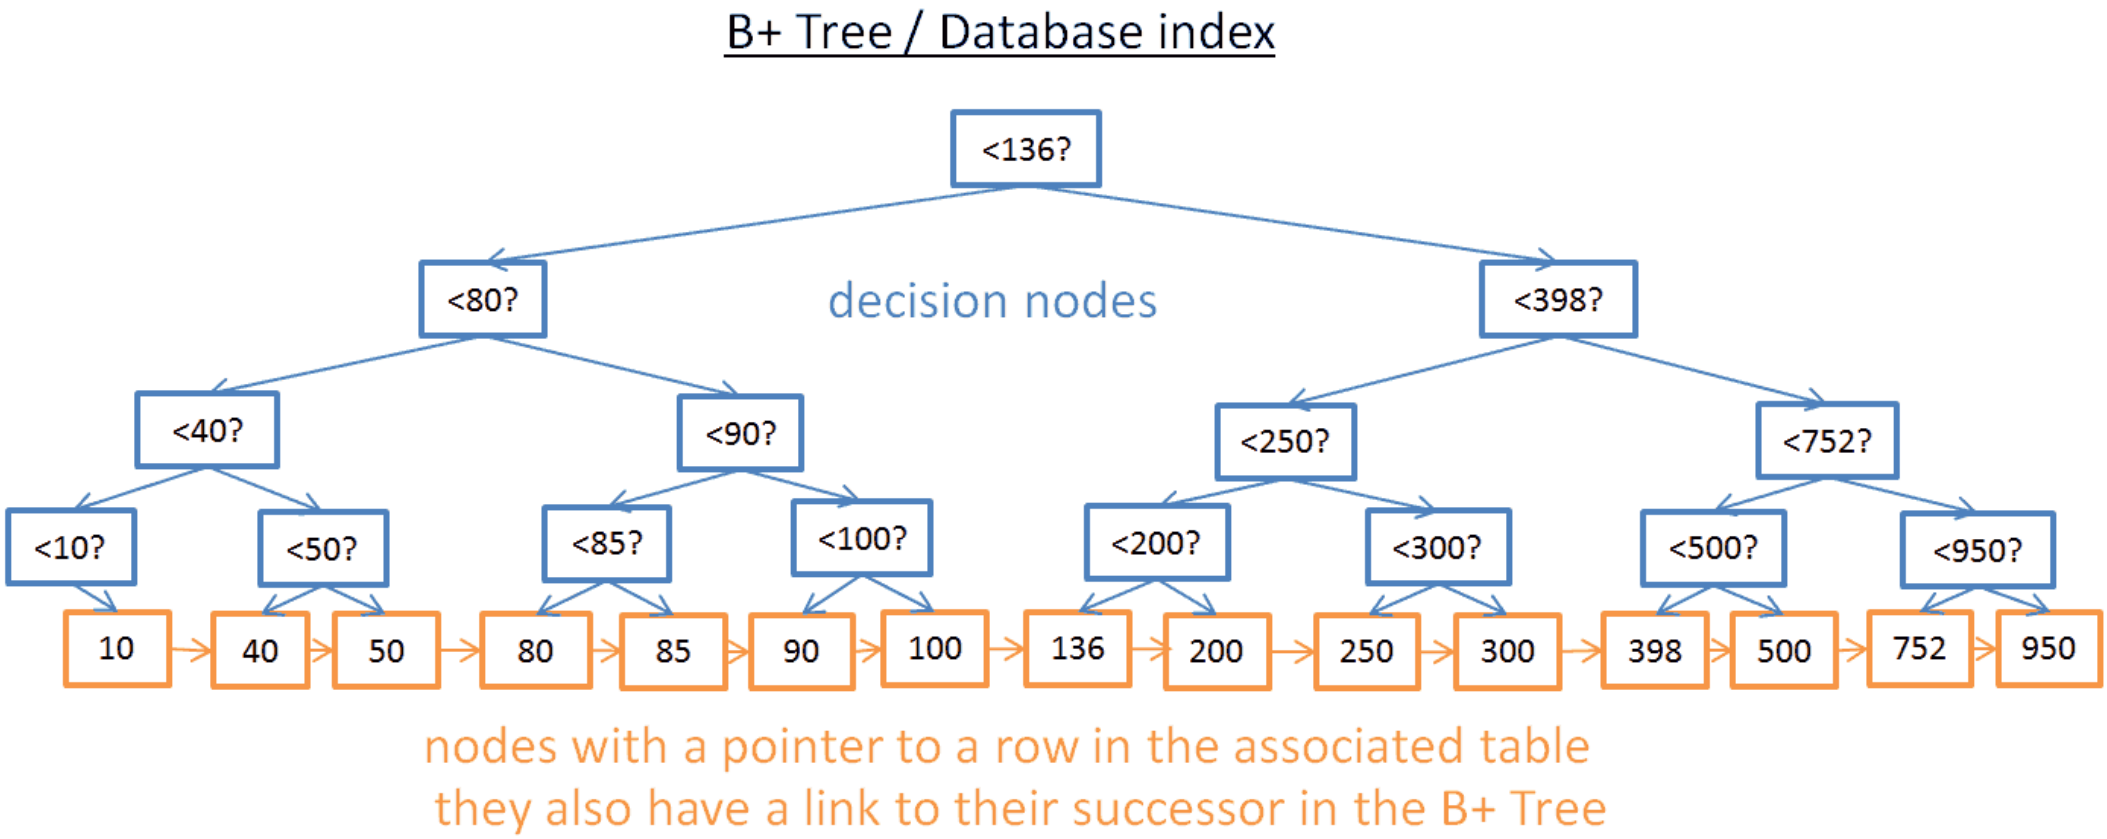

Werking van een INDEX

- Opmerkingen:
  - Wanneer tabel word aangepast: word index aangepast
  - Index: ook op niet-unieke kolom
  - Op één tabel:
    - meerdere indexen
    - één geclusterde index
  - Samengestelde index
- Opgelet:
  - Index neemt opslagruimte in beslag
  - Als index vol is: reorganisatie van de index
- Meerdere indexvormen zijn mogelijk

Planner / Optimiser

- Conceptueel: bv denken in lussen of geneste lessen bij joins, de volgorde van verwerking van een SELECT instructie
- Concreet: intern kan dit helemaal anders verwerkt worden

- SQL is een declaratieve (programmeer)taal, geen imperatieve (programmeer)taal.
    - Idee: Je zegt wat er (logisch) moet gebeuren, niet (expliciet) hoe het moet gebeuren.
    - 1 van de sterke punten van SQL

- Redeneer conceptueel en groei

Optimiser

- Zoekt de beste strategie
  - Verwachte verwerkingstijd
  - Aantal rijen
  - Indexen
  - Interne statistieken
  - ..

CREATE INDEX

- Geen ANSI of ISO specificatie
- Vendor specificatie : https://www.postgresql.org/docs/current/sql-createindex.html

CREATE INDEX

- Postgresql:

```
CREATE INDEX spelers_postcode_idx
        ON spelers (postcode asc);
CREATE UNIQUE INDEX spelers_naam_vl_idx
      ON spelers (naam, voorletters);
-- UNIQUE !
CREATE INDEX spelers_naam_vl_partial_idx
      ON spelers (naam, voorletters)
   WHERE spelersnr < 100;
CLUSTER spelers USING speler_naam_vl_idx;
```

DELETE/UPDATE

Wat is het effect van een geclusterde index?

REINDEX

- Vendor specificatie:

  https://www.postgresql.org/docs/current/sql-reindex.html

- Postgresql:
  - `REINDEX INDEX een_index;`
  - `REINDEX TABLE een_tabel;`
  - `REINDEX DATABASE een_database;`

INDEX management

- `CREATE`
- `ALTER`
  - `ALTER INDEX groot_idx SET TABLESPACE ergens_anders;`
- `DROP`

- Meeste SQL-producten :
  - automatische creatie van index op primaire en secudaire sleutels bij het maken van de tabel
  - naam wordt afgeleid uit de naam van de tabel en de betreffende kolommen

Wanneer INDEXeren?

- Index:
  - Voordeel: index versnelt verwerking
  - Nadeel:
    - index neemt opslagruimte
    - elke mutatie vraagt aanpassing van index

    => verwerking vertraagt

Welke kolommen?

- Richtlijnen voor keuze van kolommen :
  - Unieke index op kandidaatsleutels
  - Index op refererende sleutels
  - Index op kolommen waarop (veel) geselecteerd wordt
    - Grootte van de tabel
    - Kardinaliteit (verschillende waarden) van de tabel
    - Distributie (verdeling) van de waarden
  - Index op een combinatie van kolommen
  - Index op kolommen waarop gesorteerd wordt
  - ..

Speciale indexvormen

- Multi-tabelindex :
  = index op kolommen in meerdere tabellen
- Virtuele-kolomindex :
  = index op een expressie
- Selectieve index
  = index op een selectie van de rijen
- Hash-index
  = index op basis van het adres van de pagina
- Bitmapindex
  = interessant als er veel dubbele waardes zijn

Nieuwere indexvormen: GIST en SP-GIST

- GiST (Generalized Search Tree)
  - gebalanceerd
  - template voor verschillende index schema's
  - Voor "clusters" volgens een afstandsmaat
  - Bv vergelijken van intervallen, GIS, bevat, dichtste buren, tekst
- SP-GiST (space-partitioned GiST)
  - Hoeft niet gebalanceerd te zijn
  - Geen overlap tussen de clusters (GiST)

Nieuwere indexvormen: Gin en Brin

- GIN (Generalized Inverted Index)
  - Interessant bij veel dubbele waarden
  - Er worden meerdere opzoekwaarden tegelijk aangemaakt (handig voor rij, tekst, json,..)
- BRIN : voor grote geclusterde tabellen
  - Klein, minder performant tenzij:
  - min/max waarde per blok

Conclusie

Een index op elke tabel en iedere kolom?

Samengevat

- B-tree:
  - goeie standaard, < <= = >= >
- Hash:
  - alternatief voor 1 rij, =
- GIN:
  - efficiënt bij dubbels, meerdere opzoekwaarden per veld, <@ @> = &&
- GiST:
  - veel mogelijkheden, minder performant, << &< .. <<| &<| <@ ~= &&
- Sp-GiST:
  - niet overlappende GiST, << >> ~= <@ <<| |>>
- BRIN:
  - grote geclusterde data, < <= = >= >

INDEX catalog_table

- Postgresql: pg_index

- http://www.postgresql.org/docs/current/static/catalog-pg-index.html
- http://www.postgresql.org/docs/current/static/internals.html

- Referenties: Index Internals, Heikki Linnakangas (Pivotal)
- https://www.pexels.com/photo/blurred-book-book-pages-literature-46274/